

# NumPy KÜTÜPHANESİ


NumPy kütüphanesi, veri manipülasyonun temel işlemlerinde kullanılan “Python” kütüphanesidir. Bu kütüphane bize çok boyutlu dizilerde yüksek performansta çalışmayı sağlar.



NumPy’ı projemizde kullanabilmek için **import** etmemiz gerekmektedir:

```
import numpy as np
```

## NUMPY ARRAY’İ NEDİR?



```
a = np.array([1,2,3])
b = np.array([(1.5,2,3), (4,5,6)], dtype = float)
c = np.array([(1.5,2,3), (4,5,6)], [(3,2,1), (4,5,6)]], dtype = float)
```

## NUMPY ARRAY OLUŞTURULMASI

- np.zeros(size)**=> Tüm elemanları sıfır olan size boyutunda bir np array oluşturur.
- np.ones(size)**=> Tüm elemanları bir size boyutunda bir np array oluşturur.
- np.full(size,sayı)**=> Tüm elemanları “sayı” parametresi olan size boyutunda np arrayi oluşturur.
- np.arange(aralık,artış)**=>Verilen aralığa ve artış miktarına göre numpy dizisi oluşturur.
- np.eye(sayı)**=>Verilen sayı boyutunda birim matris oluşturur.

- np.empty(size)**=>Verilen boyut kadar boş bir dizi oluşturur.
- np.array([a,b,c])**=>Verilen arrayi np arrayine dönüştürür.
- np.random.randint(size)**=>Rastgele değerlere sahip bir dizi oluştururuz.

## NUMPY ARRAY ÖZELLİKLERİ

- a.shape**=> Boyut bilgisi (a) yada (a, b) şeklinde gösterir.
- len(a)**=> Arrayin uzunluğunu verir.
- b.ndim**=> Boyut sayısını 1-2-3 şeklinde gösterir.
- e.size**=> Toplam eleman sayısını verir.
- b.dtype**=> Dizinin veri tipini gösterir.
- b.dtype.name**=> Veri türünün adını döndürür.
- b.astype(int)**=> Bir diziyi farklı bir veri tipine dönüştürür.

## NUMPY ARRAYLERİNDE ARİTMETİK İŞLEMLER

- np.subtract(a,b)** => Çıkarma işlemi
- np.add(b,a)** => Toplama işlemi
- np.multiply(a,b)** => Çarpma işlemi
- np.exp(b)**=> Üs alma işlemi
- np.sqrt(b)**=> Karekök alma işlemi
- np.sin(a)**=> Bir dizinin sinüslerini yazdır.
- np.cos(b)**=> Eleman eleman kosinüslerini yazdırır.
- np.log(a)**=> eleman eleman logaritmalarını yazdırır.

```
e.dot(f)
```

## NUMPY ARRAYLERİNDE AGGREGATE İŞLEMLERİ

- a.sum()**=> dizi bazında toplam
- a.min()**=> Dizi bazında minimum değeri
- b.max(axis=0)** => Bir dizi satırının maksimum değeri
- b.cumsum(axis=1)** => Öğelerin kümülatif toplamı
- a.mean()** => Ortalama
- b.median()** => Ortanca Değer
- a.corrcoef()** => Korelasyon katsayısı
- np.std(b)** => Standart sapma

## NUMPY ARRAYLERİNDE KOPYALAMA VE SIRALAMA İŞLEMLERİ

- h = a.view()** => Aynı verilerle dizinin bir görünümünü oluşturun
- np.copy(a)** => Dizinin bir kopyasını oluşturun
- h = a.copy()** => Dizinin derin bir kopyasını oluşturun
- a.sort()** => Dizileri küçükten büyüğe sıralar
- c.sort(axis= 0)**=> Bir dizinin ekseninin öğelerini sıralama

## NUMPY ARRAYLERİNDE SLICING VE FANCY İŞLEMLERİ

Bunları birkaç alt başlıkta inceleyeceğiz:

❖ **Subsetting**

- ✚ `a[2]` => 2. dizindeki öğeyi seçin : 3
- ✚ `b[1,2]` => 1. satır sütunundaki öğeyi seçin : 2 6.0 (eşiti `b[1][2]`)

❖ **Slicing**

- ✚ `a[0:2]` => 0 ve 1 dizisindeki öğeleri seçin : array ([1, 2])
- ✚ `b[0:2,1]` => 1. sütunda 0 ve 1. satırdaki öğeleri seçin :array([ 2., 5.])
- ✚ `b[:1]` => 0 satırındaki tüm öğeleri seç array([1.5, 2., 3.]) (eşiti `b[0:1, :]`)
- ✚ `c[1,...]` aynıdır [1,,:]
- array([[ 3., 2., 1.], [ 4., 5., 6.]])
- ✚ `a[: -1]` bir diziyi ters çevirir : array([3, 2, 1])

❖ **FANCY Indexing**

- ✚ `b[[1, 0, 1, 0],[0, 1, 2, 0]]` Seçilen Elemanlar: (1,0),(0,1),(1,2) and (0,0) array([ 4. , 2. , 6. , 1.5])
- ✚ `b[[1, 0, 1, 0]][:,[0,1,2,0]]` => Matrisin satır dizisinin ve sütunlarının bir alt kümesini seçin

## NUMPY ARRAYLERİNDE MANİPÜLASYON İŞLEMLERİ

Bunları birkaç alt başlıkta inceleyeceğiz:

❖ **Transposing array**

- ✚ `i = np.transpose(b)` => Dizi boyutlarınca izin ver
- ✚ `i.T` => Dizi boyutlarınca izin ver

❖ **Changing Array Shape**

- ✚ `b.ravel()` => Diziyi düzleştir
- ✚ `g.reshape(3,-2)` => Yeniden şekillendirin, ancak verileri değiştirmeyin

❖ **Adding/Removing Elements**

- ✚ `h.resize((2,6))` => Şekli olan yeni bir dizi döndür : (2,6)
- ✚ `np.append(h,g)` => Diziye bir eleman ekler
- ✚ `np.insert(a, 1, 5)` => Bir diziyi öğe ekleme
- ✚ `np.delete(a,[1])` => Diziden eleman siler

❖ **Combining Arrays**

- ✚ `np.concatenate((a,d),axis=0)` => Dizileri birleştir  
array([ 1, 2, 3, 10, 15, 20])
- ✚ `np.vstack((a,b))` Dizileri dikey olarak yığar (satır satır)  
array([[ 1. , 2. , 3. ],  
[ 1.5, 2. , 3. ],

[ 4. , 5. , 6. ]])

- ✚ `np.r_[e,f]` Dizileri dikey olarak yığar (satır satır)
- ✚ `np.hstack((e,f))` Dizileri yatay olarak yığar (sütun sütun)

array([[ 7., 7., 1., 0.],

[ 7., 7., 0., 1.]])

- ✚ `np.column_stack((a,d))` => Yığılmış sütun bazında diziler oluşturun

array([ [ 1, 10],

[ 2, 15],

[ 3, 20]])

- ✚ `np.c_[a,d]` Yığılmış sütun bazında diziler oluşturun

❖ **Splitting Arrays**

- ✚ `np.hsplit(a,3)` => Diziyi 3'te yatay olarak bölün  
[array([1]),array([2]),array([3])] index
- ✚ `np.vsplit(c,2)` => Diziyi 2. dizinde dikey olarak böl

# PANDAS KÜTÜPHANESİ

Pandas kütüphanesi NumPy kütüphanesinden sonra ve onun üzerine kurulmuştur. Python programalama dili için kullanımı kolay veri yapıları ve veri analizi araçları sağlamaktadır.

Pandas kütüphanesini projemizde kullanabilmek için **import** etmemiz gerekmektedir.

✚ Import pandas as pd

## PANDAS VERİ YAPILARI

Pandas kütüphanesinde tanımamız gereken en önemli iki kavram pandas serileri ve dataframelerdir.

### ❖ Pandas Serileri

Herhangi bir veri türünü tutabilen “Tek Boyutlulu” etiketli dizilerdir.

✚ `s = pd.Series([3, -5, 7, 4], index=['a', 'b', 'c', 'd'])`

bu kodun çıktısı =>

a	3
b	-5
c	7
d	4

### ❖ Pandas Dataframe

Potansiyel olarak farklı türlerde sütunlara sahip iki boyutlu etiketli bir veri yapısıdır.

Columns →		Country	Capital	Population
Index →	0	Belgium	Brussels	11190846
	1	India	New Delhi	1303171035
	2	Brazil	Brasilia	207847528

✚ `Data = {'Country': ['Belgium', 'India', 'Brazil'], 'Capital': ['Brussels', 'New Delhi', 'Brasilia'], 'Population': [11190846, 1303171035, 207847528]}`

✚ `Df = pd.DataFrame(data, columns = ['Country', 'Capital', 'Population'])`

## .DROP() VERİ SİLME FONKSİYONU

**Drop( silinecek alan adı, axis )** fonksiyonu kullanılmaktadır. axis parametresi alır ve “axis = 0” ise satırları, “axis = 1” ise seçilmiş sütunları siler.

✚ `s.drop(['a', 'c'])`

✚ `df.drop('Country', axis = 1)`

## OKUMA VE YAZMA CSV VEYA EXCELE

✚ `pd.read_csv('filename.csv', header = None, nrows= 5)`

✚ `df.to_csv('myDataFrame.csv')`

✚ `pd.read_excel('file.xlsx')`

✚ `df.to_excel('dir/myDataFrame.xlsx', 'Sheet1')`

## SEÇİM İŞLEMLERİ

### ❖ Getting işlemleri

✚ Bir eleman seçmek işlemleri => `s['b']`

✚ DataFrameden eleman seçme işlemleri => `df[1:]`

### ❖ Selecting, Boolean Indexing & Setting

#### Konumuna Göre Seçim

✚ `df.iloc[[0],[0]]` => Satır ve sütuna göre tek bir değer seçin

✚ `df.iat([0],[0])`

#### Etikete Göre Seçim

✚ `df.loc[[0], ['Country']]` => Satır ve sütun etiketlerine göre tek bir değer seçin

✚ `df.at([0], ['Country'])`

#### Hem Konuma Hem Etikete Göre Seçim

✚ `df.ix[2]` => tek satırlık satır alt kümesini seç

✚ `df.ix[:, 'Capital']` => Sütunların alt kümesinin tek bir sütununu seçin.

✚ `df.ix[1, 'Capital']` => Satırları ve sütunları seçiniz

#### İndekslerin Bool Kontrolü

✚ `s[~(s > 1)]` => dizide değeri -1 olmayan değerleri döndürür.

✚ `s[(s < -1) | (s > 2)]` => değeri -1 den küçük veya 2 den büyük değerleri döndürür.

✚ `df[df[ ]>1200000000] =>` DataFrame'i ayarlamak için filtreyi kullanın

### Var Olan Değerleri Değiştirme

✚ `s['a'] = 6 =>` Dizi s'nin a indeksini 6'ya ayarla

## SERİLER VE DATAFRAMELERİN BİLGİLERİNİ ÖĞRENME

✚ `df.shape =>`(sıra\_sayısı,sütun\_sayısı)

✚ `df.index =>` Dizini tanımlar

✚ `df.columns =>` Dataframın sütunlarını tanımlar

✚ `df.info() =>` Dataframe hakkında bilgi verir

✚ `df.count() =>`NA olmayan değerlerin sayısını verir

✚ `df.sum() =>` Değerlerin toplamını verir

✚ `df.cumsum() =>` Değerlerin kümülatif toplamını verir.

✚ `df.min()/df.max() =>` Maksimum ve minimum değerleri verir.

✚ `df.idxmin()/df.idxmax() =>` Maksimum ve minimum değerlerin indexlerini verir.

✚ `df.describe() =>` istatistiklerin özetini gösterir.

✚ `df.mean() =>` Ortalamasını verir.

✚ `df.median() =>` Ortanca değerini verir.

## FONKSİYON UYGULAMA

✚ `f = lambda x: x*2`

✚ `df.apply(f) =>` Fonksiyonu uygular

✚ `df.applymap(f) =>`Fonksiyonu element element uygular.

## VERİ HİZALAMA

NA değerleri, örtüşmeyen indekslere verilir. Örneğin s serimiz 4 etikete sahip bir seriydi 3 etiketli bir seri ile toplarsak sonucumuz şu şekildedir:

✚ `s3 = pd.Series([7, -2, 3], index=[ 'a' , 'c' , 'd'])`

✚ `s + s3`

a	10
b	Nan
c	5
d	3

Eğerki NaN sonucu elde etmek istemiyorsanız doldurma metotlarıyla kendinizde yapabilirsiniz. Örneğin:

✚ `s.add(s3, fill_values=0)`

a	10
b	-5
c	5
d	3

✚ `s.sub(s3, fill_value=2)`

✚ `s.div(s3, fill_value=4)`

✚ `s.mul(s3, fill_value=3)`

# SCIKIT-LEARN KÜTÜPHANESİ

Scikit-learn, birleşik bir arayüz kullanarak bir dizi makine öğrenimi, ön işleme, çapraz doğrulama ve görselleştirme algoritmaları uygulayan açık kaynaklı bir Python kütüphanesidir.

## Basit Bir Örneği:

```
from sklearn import neighbors, datasets, preprocessing
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
iris = datasets.load_iris()
X, y = iris.data[:, :2], iris.target >>> X_train, X_test, y_train, y_test = train_test_split(X, y, random_state=33)
Scaler= preprocessing.StandardScaler().fit(X_train )
X_train = scaler.transform(X_train)
X_test = scaler.transform(X_test)
knn = neighbors.KNeighborsClassifier(n_neighbors=5)
knn.fit(X_train, y_train)
y_pred = knn.predict(X_test)
accuracy_score(y_test, y_pred)
```

## VERİLERİMİZİ YÜKLEME

Verilerimizin sayısal olması ve Numpy dizileri veya Scipy sparse matrisleri olarak saklanması gerekmektedir. Pandas

dataframeleri gibide sayısal dizilere dönüştürülebilen diğer türlerde kabul edilmektedir.

```
import numpy as np
X = np.random.random((10,5))
y = np.array([ 'M', 'M', 'F', 'F', 'M', 'F', 'M', 'M', 'F', 'F'])
X[X < 0.7] = 0
```

## EĞİTİM VE TEST DATALARI

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, random_state=0)
```

## MODEL OLUŞTURMA

### ❖ Denetimli Öğrenme

```
lr.fit(X, y) => Modeli verilere sığdırır
knn.fit(X_train, y_train)
svc.fit(X_train, y_train)
```

### ❖ Denetimsiz Öğrenme

```
k_means.fit(X_train) => Modeli verilere sığdırır
pca_model = pca.fit_transform(X_train) => Modeli veriye sığdırır, sonra dönüştürür
```

## TAHMİN

### ❖ Denetimli Tahminçiler

```
y_pred = svc.predict(np.random.random((2,5))) => Etiketleri tahmin et
y_pred = lr.predict(X_test) => Etiketleri tahmin et
```

```
y_pred = knn.predict_proba(X_test)=> Bir etiketin tahmini olasılığı
```

### ❖ Denetimsiz Tahminçiler

```
y_pred = k_means.predict(X_test) => Kümeleme algoritmalarında etiketleri tahmin edin
```

## VERİLERİ ÖN İŞLEME

### ❖ Standardizasyon

```
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler().fit(X_train)
standardized_X = scaler.transform(X_train)
standardized_X_test = scaler.transform(X_test)
```

### ❖ Normalizasyon

```
from sklearn.preprocessing import Normalizer
scaler = Normalizer().fit(X_train)
normalized_X = scaler.transform(X_train)
normalized_X_test = scaler.transform(X_test)
```

### ❖ Binarizasyon

```
from sklearn.preprocessing import Binarizer
binarizer = Binarizer(threshold=0.0).fit(X)
binary_X = binarizer.transform(X)
```

### ❖ Kategorik Özelliklerin Kodlanması

```
from sklearn.preprocessing import Binarizer
binarizer = Binarizer(threshold=0.0).fit(X)
binary_X = binarizer.transform(X)
```

## ❖ Eksik Değerleri Atama

```
from sklearn.preprocessing import Imputer
imp = Imputer(missing_values=0, strategy= , a
xis=0)
imp.fit_transform(X_train
```

## ❖ Polinom Özellikleri Oluşturma

```
from sklearn.preprocessing import
PolynomialFeatures
poly = PolynomialFeatures(5)
poly.fit_transform(X)
```

## MODEL OLUŞTURMA

## ❖ Lineer Regresyon

```
from sklearn.linear_model import Linear
Regression
lr = LinearRegression(normalize = True )
```

## ❖ Support Vektor Machines (SVM)

```
from sklearn.svm import SVC
svc = SVC(kernel= 'linear' )
```

## ❖ Naive Bayes

```
from sklearn.naive_bayes import GaussianNB
gnb = GaussianNB()
```

## ❖ KNN

```
from sklearn import neighbors
knn =
neighbors.KNeighborsClassifier(n_neighbors=5)
```

## ❖ Principal Component Analysis (PCA)

```
from sklearn.decomposition import PCA
pca = PCA(n_components=0.95)
```

## ❖ K means

```
from sklearn.cluster import KMeans
k_means = KMeans(n_clusters=3, random_state=0)
```

## MODELİN PERFORMANSINI DEĞERLENDİRME

## ❖ Sınıflandırma Metrikleri

## Doğruluk Puanı

```
knn.score(X_test, y_test)=> Tahmin edici puan
metodu
from sklearn.metrics import accuracy_score =>
metrik puanlama fonksiyonu
accuracy_score(y_test, y_pred)
```

## Sınıflandırma Raporu

```
from sklearn.metrics import classification_report
=> Kesinlik, geri çağırma, f1- puanı ve destek
print(classification_report(y_test, y_pred))
```

## Karışıklık Matrisi

```
from sklearn.metrics import confusion_matrix
print (confusion_matrix ( y_test, y_pred))
```

## ❖ Regresyon Metrikleri

## Ortalama Mutlak Hata

```
from sklearn.metrics import mean_absolute_error
y_true = [3, 0.5, 2]
mean_absolute_error(y_true, y_pred)
```

## Ortalama Kare Hatası

```
from sklearn.metrics import mean_squared_error
mean_squared_error(y_test, y_pred)
```

R<sup>2</sup> Score

```
from sklearn.metrics import r2_score
r2_score(y_true, y_pred)
```

## ❖ Kümeleme Metrikleri

## Düzeltilmiş Rand Endeksi

```
from sklearn.metrics import adjusted_rand_score
adjusted_rand_score(y_true, y_pred)
```

## Homojenlik

```
from sklearn.metrics import homogeneity_score
homogeneity_score(y_true, y_pred)
```

## V-Ölçümü

```
from sklearn.metrics import homogeneity_score
homogeneity_score(y_true, y_pred)
```

## ❖ Çapraz Geçerleme

```
from sklearn.cross_validation import
cross_val_score
print(cross_val_score(knn, X_train, y_train, cv=
4))
print(cross_val_score(lr, X, y, cv=2))
```